Análise Comparativa de Representações em Algoritmos Genéticos para o Job Scheduling Problem

Tomás Ferreira
2025168427

Eduardo Pereira
2021233890

Inteligência Artificial Inspirada na Natureza

Universidade de Coimbra
Faculdade de Ciências e Tecnologia

Chapter 1

Introdução

O *Job Scheduling Problem* (JSP) é um problema de natureza combinatória e de elevada complexidade. Por esse motivo, é comum recorrer a métodos heurísticos, como os Algoritmos Genéticos (AGs), capazes de obter boas soluções em tempos aceitáveis.

Este trabalho foca-se na comparação de duas formas de representar as soluções nos AGs: a representação Binária e a representação por Permutação. O objetivo é analisar de que modo a escolha da codificação influencia o comportamento do algoritmo, nomeadamente a eficácia dos operadores genéticos e a correspondência entre a solução codificada e a solução real do problema.

O principal objetivo do estudo é identificar qual destas abordagens oferece o melhor equilíbrio entre a qualidade da solução, medida pelo *makespan*, a velocidade de convergência e a capacidade de lidar com problemas de maior dimensão. Para isso, foi seguida uma metodologia experimental estruturada, que incluiu a calibração dos parâmetros de mutação e *crossover*, a análise dos diferentes mecanismos de seleção e a realização de testes com variação do número de *jobs* (N) e de *machines* (M). Este relatório apresenta de forma detalhada estas decisões e a análise estatística dos resultados, com o intuito de identificar a configuração mais robusta para cenários de complexidade crescente.

Chapter 2

Metodologia

O desenho experimental deste estudo foi estruturado de forma sistemática para isolar e avaliar o impacto individual de cada componente dos Algoritmos Genéticos, garantindo que as comparações entre representações não são enviesadas por configurações arbitrárias. A estratégia de validação estrutura-se em três fases sequenciais: a Calibração de Parâmetros, a Análise de Mecanismos e, finalmente, os Testes de Escalabilidade.

O presente capítulo detalha a operacionalização destas etapas e as respetivas condições de teste. Nas fases de calibração e análise de mecanismos, normalizou-se o esforço computacional fixando a dimensão da população e o número de gerações. Esta decisão metodológica visa garantir a equidade comparativa, assegurando que ambos os métodos beneficiam das mesmas oportunidades de aprendizagem. Deste modo, isola-se a eficiência de cada configuração, garantindo que as variações de desempenho decorrem do algoritmo e não do volume de exploração.

2.1 Calibração de Parâmetros

Nesta fase inicial, o principal objetivo foi identificar as combinações das probabilidades de crossover (P_c) e de mutação (P_m) que proporcionam o melhor desempenho para cada tipo de representação. Para esse efeito, adotou-se uma abordagem de *grid search*, permitindo avaliar sistematicamente todas as combinações consideradas.

Neste procedimento, foram testadas todas as combinações possíveis entre cinco valores da taxa de crossover ($P_c \in 0.5, 0.6, 0.8, 0.9, 0.95$) e cinco valores da taxa de mutação ($P_m \in 0.01, 0.05, 0.1, 0.2, 0.4$), totalizando 25 configurações diferentes para cada representação. Esta abordagem permitiu não só comparar diferentes parametrizações, mas também identificar efeitos de interação entre os dois operadores genéticos.

A avaliação do desempenho destas configurações baseou-se em duas métricas principais, analisadas de forma complementar:

1. **Qualidade da Solução:** Avaliada através da média e do desvio padrão do *makespan*. Na análise destes valores, foi dada prioridade à obtenção de valores médios mais baixos, sem negligenciar a estabilidade dos resultados. Sempre que duas configurações apresentem desempenhos médios semelhantes, privilegia-se aquela que apresenta menor desvio padrão, por refletir maior consistência e previsibilidade dos resultados.

2. **Velocidade de Convergência:** Avaliada tendo em conta o equilíbrio entre eficiência computacional e qualidade da solução. Embora uma convergência rápida seja desejável, não é considerada vantajosa quando compromete a qualidade final. Assim, são valorizadas as configurações que alcançam bons resultados em menos gerações, penalizando-se aquelas que convergem demasiado cedo para soluções de baixa qualidade.

2.1.1 Resultados Experimentais

As Tabelas 2.1 e 2.2 apresentam os dados quantitativos para as representações Binária e de Permutação, respetivamente, incluindo a média e desvio padrão do *makespan*, bem como a geração média em que ocorre a convergência, com base em cinco execuções por configuração. Adicionalmente, a Figura 2.1 sintetiza visualmente estes resultados através de *heatmaps*, facilitando a identificação das regiões com melhor desempenho.

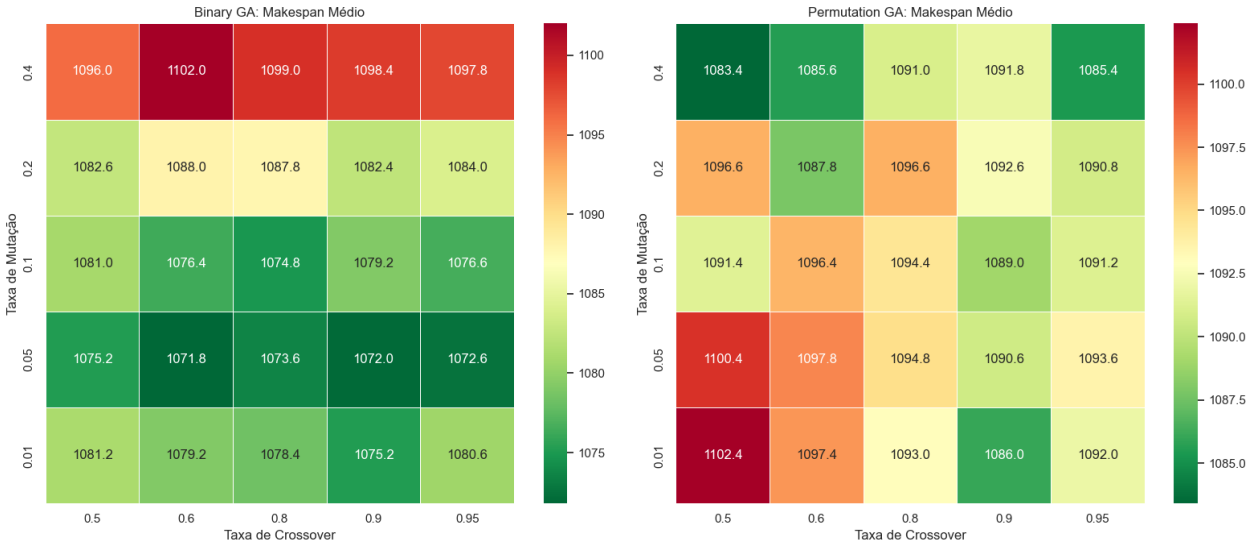

Figure 2.1: *Heatmaps* resultantes do Grid Search, ilustrando o Makespan médio para as representações Binária e Permutação em função das taxas de Crossover e Mutação. As zonas de tom verde mais escuro indicam melhor desempenho (menor makespan).

Table 2.1: Resultados do Grid Search para a Representação Binária (Média de 5 execuções). A melhor configuração está destacada a negrito.

Configuração	P_c	P_m	**Makespan Médio**	**Std. Dev**	**Conv. (Geração)**
C0.5_M0.01	0.5	0.01	1081.2	10.87	16.8
C0.5_M0.05	0.5	0.05	1075.2	7.53	12.6
C0.5_M0.1	0.5	0.1	1081.0	1.41	14.2
C0.5_M0.2	0.5	0.2	1082.6	5.13	12.8
C0.5_M0.4	0.5	0.4	1096.0	8.03	9.4
C0.6_M0.01	0.6	0.01	1079.2	7.36	14.0
C0.6_M0.05	**0.6**	**0.05**	**1071.8**	**7.26**	**14.4**
C0.6_M0.1	0.6	0.1	1076.4	4.98	15.2
C0.6_M0.2	0.6	0.2	1088.0	4.24	10.6
C0.6_M0.4	0.6	0.4	1102.0	5.61	9.4
C0.8_M0.01	0.8	0.01	1078.4	5.98	14.8
C0.8_M0.05	0.8	0.05	1073.6	11.84	10.4
C0.8_M0.2	0.8	0.2	1087.8	1.92	10.8
C0.8_M0.4	0.8	0.4	1099.0	3.87	13.2
C0.9_M0.05	0.9	0.05	1072.0	9.46	14.0
C0.9_M0.4	0.9	0.4	1098.4	3.78	5.6
C0.95_M0.05	0.95	0.05	1072.6	7.30	13.0
C0.95_M0.4	0.95	0.4	1097.8	4.09	10.4

Table 2.2: Resultados do Grid Search para a Representação de Permutação (Média de 5 execuções). A melhor configuração está destacada a negrito.

Configuração	P_c	P_m	**Makespan Médio**	**Std. Dev**	**Conv. (Geração)**
C0.5_M0.01	0.5	0.01	1102.4	7.23	7.6
C0.5_M0.05	0.5	0.05	1100.4	2.07	8.2
C0.5_M0.2	0.5	0.2	1096.6	7.02	12.8
C0.5_M0.4	**0.5**	**0.4**	**1083.4**	**4.45**	**16.8**
C0.6_M0.05	0.6	0.05	1097.8	7.76	6.8
C0.6_M0.2	0.6	0.2	1087.8	7.95	11.6
C0.6_M0.4	0.6	0.4	1085.6	11.48	16.0
C0.8_M0.01	0.8	0.01	1093.0	9.75	8.2
C0.8_M0.2	0.8	0.2	1096.6	5.41	10.6
C0.8_M0.4	0.8	0.4	1091.0	5.15	10.4
C0.9_M0.01	0.9	0.01	1086.0	5.57	10.4
C0.9_M0.2	0.9	0.2	1092.6	8.59	8.2
C0.95_M0.01	0.95	0.01	1092.0	6.75	11.6
C0.95_M0.05	0.95	0.05	1093.6	4.67	12.8

2.1.2 Análise Crítica e Discussão

A análise conjunta das Tabelas 2.1 e 2.2, juntamente com os *heatmaps* da Figura 2.1, revela padrões de comportamento distintos entre os operadores em cada abordagem.

No caso da Representação Binária, observa-se uma forte relação negativa entre a taxa de mutação e a qualidade da solução. Como mostram a Tabela 2.1 e a área vermelha no topo do heatmap correspondente, as configurações com mutação elevada ($P_m = 0.4$) registam sistematicamente os piores valores de *makespan* (por exemplo, 1102.0 para `C0.6_M0.4`), independentemente da taxa de crossover. Isto indica que uma mutação excessiva destrói os esquemas de prioridade que o algoritmo tenta construir, tornando a pesquisa quase aleatória. A região de melhor desempenho situa-se consistentemente para valores de mutação entre $P_m = 0.05$ e 0.1, sendo a configuração C0.6_M0.05 a que apresenta o melhor resultado absoluto (1071.8), combinando uma exploração estável com um desvio padrão moderado, o que sugere robustez.

Por outro lado, a Representação de Permutação (Tabela 2.2 e Figura 2.1, à direita) mostra que configurações com mutação muito baixa ($P_m = 0.01$), normalmente recomendadas para problemas de ordenação para não destruir sequências, levam a convergências prematuras e soluções subótimas (por exemplo, 1102.4 para `C0.5_M0.01`), a menos que sejam combinadas com um crossover muito agressivo.

O dado mais relevante foi o desempenho da configuração C0.5_M0.4, que registou o melhor *makespan* médio de todo o conjunto de permutação (1083.4). Isto indica que, quando a taxa de crossover é baixa ($P_c = 0.5$), o algoritmo beneficia de uma mutação elevada (40%), utilizando o operador de troca como principal mecanismo para escapar de ótimos locais e manter a diversidade da população até gerações mais tardias (convergência média na geração 16.8).

2.1.3 Seleção de Parâmetros

Com base nos resultados obtidos, foram escolhidas as configurações que passam para a fase de Análise de Mecanismos:

- **Binário:** Seleciona-se $P_c = 0.6, P_m = 0.05$. Esta combinação mostrou-se mais eficaz na preservação da estrutura das soluções, permitindo minimizar o *makespan* final com elevada consistência.
- **Permutação:** Seleciona-se $P_c = 0.5, P_m = 0.4$. Esta configuração foi escolhida por proporcionar maior capacidade de exploração, evitar convergência prematura e alcançar o menor *makespan* entre todas as configurações testadas.

2.1.4 Análise da Sensibilidade à Dimensão da População

Após a identificação das taxas ótimas de crossover e mutação, realizou-se uma análise adicional para avaliar o impacto do tamanho da população na qualidade da solução. Dado que na fase anterior se utilizou uma população reduzida ($N = 10$) para otimizar o *grid search*, tornou-se imperativo verificar se o aumento dos recursos computacionais se traduziria numa melhoria significativa no *makespan*.

Para isso, usaram-se os melhores valores de parâmetros encontrados antes ($P_c = 0.6, P_m = 0.05$ para Binário e $P_c = 0.5, P_m = 0.4$ para Permutação) e manteve-se o limite de 100 gerações. Primeiro, testaram-se quatro tamanhos de população ($N = 10, 20, 50, 100$). Como a Representação de Permutação continuava a melhorar com populações maiores, decidiu-se testar até $N = 450$ para ver até onde o algoritmo consegue evoluir.

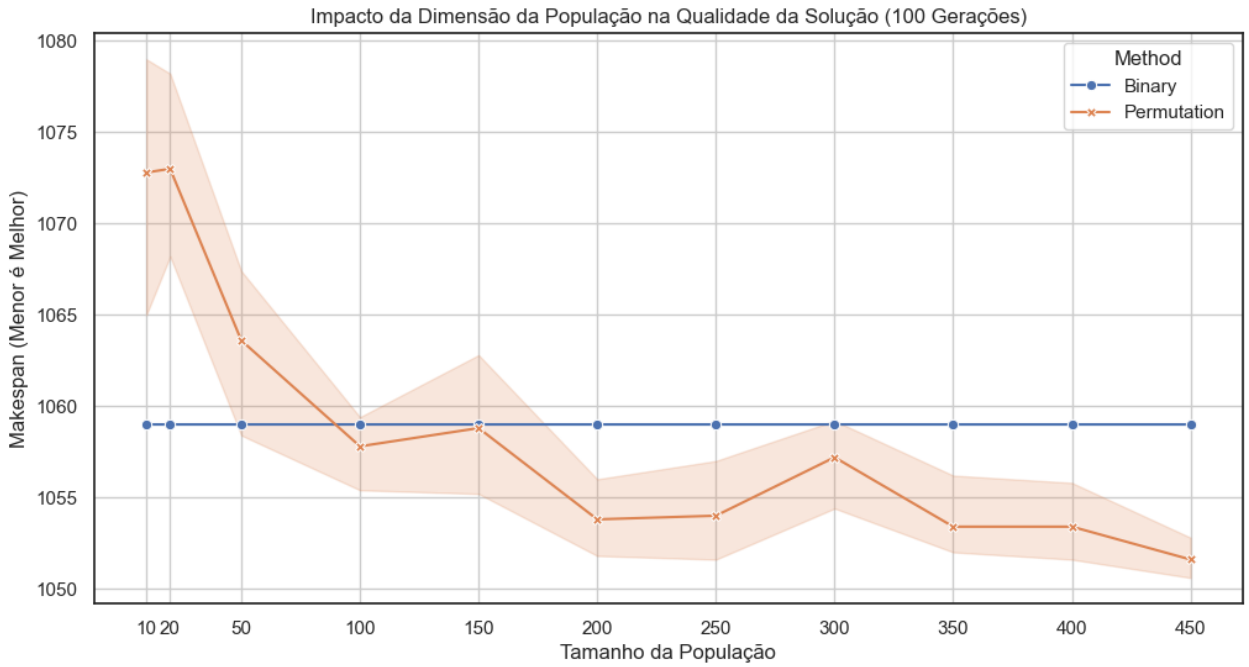

Figure 2.2: Evolução comparativa da qualidade da solução (Makespan médio) em função da dimensão da população ($N \in [10, 450]$). As áreas sombreadas representam o intervalo de confiança.

Os resultados, ilustrados na Figura 2.2 e detalhados na Tabela 2.3, revelam uma dicotomia fundamental no comportamento das duas representações.

A Representação Binária atingiu rapidamente um limite, convergindo sempre para o valor 1059.0 em todas as configurações (Desvio Padrão = 0.00), mesmo quando a população foi aumentada para 450 indivíduos. Este comportamento mostra uma limitação da codificação binária simples para problemas de sequenciamento grandes. Como o genótipo usa apenas bits 0 e 1, surgem muitos empates na descodificação por prioridades, o que limita muito a capacidade do algoritmo de gerar soluções diferentes e faz com que ele fique preso a um ótimo

local simples.

Por outro lado, a Representação de Permutação aproveitou o aumento do tamanho da população, reduzindo gradualmente o *makespan* médio até atingir o valor mínimo de 1051.6 com $N = 450$. No entanto, a análise mostra rendimentos decrescentes: aumentar a população de $N = 10$ para $N = 100$ trouxe um ganho de cerca de 1,4%, enquanto o aumento de $N = 100$ para $N = 450$ resultou num ganho muito menor, de apenas 0,6%.

Table 2.3: Impacto da dimensão da população na qualidade da solução (Seleção de dados representativos).

Método	**População (N)**	**Makespan Médio**	**Std. Dev**	**Conv. (Geração)**
Binary	10–450	1059.0	0.00	–
Permutation	10	1072.8	8.76	52.2
Permutation	50	1063.6	5.86	70.8
Permutation	100	1057.8	2.77	42.6
Permutation	**200**	**1053.8**	**2.77**	**71.6**
Permutation	300	1057.2	3.11	63.6
Permutation	450	1051.6	1.52	64.2

2.1.5 Definição dos Parâmetros Finais

Face à evidência de que a melhoria da qualidade tende a estabilizar a partir de certas dimensões, impõe-se uma decisão de compromisso entre qualidade e eficiência para as fases seguintes de Análise de Mecanismos e Testes de Escalabilidade:

- **Dimensão da População:** Fixa-se em $N = 200$. A análise da Figura 2.2 demonstra que esta dimensão oferece o melhor equilíbrio entre a qualidade da solução e o esforço computacional. Com $N = 200$, atinge-se um patamar de qualidade elevada (1053.8) e excelente estabilidade (Std. Dev 2.77), capturando a maior parte dos ganhos de desempenho sem incorrer no custo excessivo das configurações de $N = 450$.

- **Critério de Paragem:** Mantém-se em 100 Gerações. Considerando que a convergência média para a configuração escolhida ($N = 200$) ocorre na geração 71.6, este limite oferece a margem de segurança necessária para garantir que o processo evolutivo não é interrompido prematuramente, permitindo uma melhor exploração do espaço de procura.

2.2 Análise de Mecanismos Evolutivos

Após a calibração dos parâmetros numéricos, nomeadamente as taxas de *mutation*, *crossover* e o *population size*, a segunda fase do estudo centrou-se na análise da arquitetura dos Genetic Algorithms (GAs) utilizados. O objetivo principal foi avaliar o impacto dos diferentes operadores genéticos (*parent selection*, *survivor selection*, *crossover* e *mutation*) no desempenho global do algoritmo para o *Job Scheduling Problem*, considerando as diferentes representações adotadas.

No que diz respeito aos operadores representation-independent, foram analisados os métodos de parent selection Tournament Selection e Roulette-Wheel Selection, bem como o método de survivor selection Elitist Selection, comuns a ambas as representações. Para a Binary Representation, foram avaliados os operadores de crossover One-Point Crossover e Uniform Crossover, bem como o operador de mutation Bit Flip Mutation. Já para a Permutation Representation, foi considerado o operador de crossover Order Crossover (OX) e os operadores de mutation Swap Mutation e Scramble Mutation.

Para esse efeito, foram testadas todas as combinações possíveis dos operadores considerados, mantendo fixos os parâmetros ótimos definidos na fase anterior ($N = 200$, 100 gerações, $P_c = 0.6$ / $P_m = 0.05$ para a representação Binária e $P_c = 0.5$ / $P_m = 0.4$ para a representação de Permutação). Esta estratégia permitiu analisar, de forma isolada, o contributo de cada operador na capacidade de exploração e na convergência do algoritmo.

2.2.1 Resultados e Discussão

A Tabela 2.4 sintetiza os resultados obtidos para as oito configurações testadas, discriminando o *makespan* médio, o desvio padrão e a geração média de convergência.

Table 2.4: Comparação de desempenho entre diferentes mecanismos evolutivos (Média de 5 execuções).

Rep.	**Configuração (Seleção + Op. Variável)**	**Makespan**	**Std. Dev**	**Conv. Gen**
Binary	1. Tournament + One-Point	1059.0	0.00	20.6
Binary	2. Tournament + Uniform	1059.0	0.00	13.6
Binary	3. Roulette + One-Point	1064.2	6.57	62.2
Binary	4. Roulette + Uniform	1063.6	5.98	76.2
Permutation	1. Tournament + Swap	**1056.2**	5.45	48.4
Permutation	2. Tournament + Scramble	1062.8	4.02	69.6
Permutation	3. Roulette + Swap	1066.2	4.44	72.2
Permutation	4. Roulette + Scramble	1071.2	2.49	60.2

Análise da Representação Binária

Os resultados obtidos para a representação binária confirmam a saturação estrutural observada nas fases anteriores. As configurações que utilizam Tournament Selection (Hipóteses 1 e 2) convergem sempre para o valor 1059.0, com desvio padrão nulo, mostrando que este operador aplica pressão seletiva suficiente para levar rapidamente a população a um ótimo local. No entanto, devido às limitações da codificação binária, o algoritmo não consegue ultrapassar esse valor.

Por outro lado, a utilização da Roulette-Wheel Selection (Hipóteses 3 e 4) levou a uma pior qualidade das soluções, com valores médios de 1064.2 e 1063.6, e a uma maior instabilidade, refletida em desvios padrão mais elevados. Este resultado indica que a pressão seletiva da roleta é demasiado fraca ou pouco consistente para este problema, permitindo que soluções de menor qualidade se mantenham na população sem contribuir de forma eficaz para a exploração do espaço de soluções. Além disso, o tipo de crossover utilizado (One-Point ou Uniform) não teve impacto relevante, uma vez que ambos produziram resultados semelhantes quando combinados com o mesmo método de seleção.

Análise da Representação de Permutação

Na representação de permutação, a escolha dos operadores teve um impacto claro nos resultados. A Tournament Selection apresentou um desempenho consistentemente superior ao da Roulette-Wheel Selection, alcançando os dois melhores valores médios. Em particular, a configuração Tournament + Swap (Hipótese 1) destacou-se ao obter o melhor *makespan* absoluto, com um valor de 1056.2.

Ao comparar os operadores de mutação sob Tournament Selection, o operador Swap apresentou melhores resultados (1056.2) do que o operador Scramble (1062.8). Embora o Scramble introduza mais diversidade ao baralhar vários genes ao mesmo tempo, os resultados mostram que, neste problema, essa alteração é demasiado agressiva e acaba por destruir sequências de tarefas que já estavam bem ajustadas. O operador Swap, por ser menos disruptivo, permitiu um ajuste mais preciso das soluções nas fases finais do processo evolutivo.

2.2.2 Seleção Final de Configurações

Com base nesta análise comparativa, definem-se as configurações finais que transitarão para a última fase de Testes de Escalabilidade:

- **Representação Binária:** Seleciona-se a configuração Tournament + Uniform Crossover. Uma vez que a qualidade da solução e a robustez são iguais entre as duas abordagens

(fitness de 1059.0 e desvio padrão de 0.00), a escolha recai sobre a eficiência computacional. O operador Uniforme demonstrou uma convergência significativamente mais rápida (13.6 contra 20.6 gerações), permitindo alcançar a melhor solução encontrada com menor consumo de recursos.

- **Representação de Permutação:** Seleciona-se a configuração Tournament + Swap Mutation. Esta combinação mostrou-se a mais eficaz e estável, ao juntar a pressão seletiva do Torneio com a capacidade do operador Swap de ajustar as soluções de forma controlada, resultando no melhor desempenho global observado em todo o estudo experimental.

2.3 Resultados Experimentais e Análise de Escalabilidade

Para avaliar a robustez e a capacidade de adaptação das abordagens propostas, o algoritmo foi testado em nove cenários diferentes ($C1$ a $C9$). Estes cenários foram definidos para analisar separadamente o impacto de duas variáveis principais: o número de *jobs* (N) e o número de *machines* (M).

A Tabela 2.5 apresenta os resultados obtidos, comparando o *makespan* médio (menor é melhor), o desvio padrão (σ) e a geração média de convergência para as representações Binária e de Permutação.

Table 2.5: Comparação de desempenho: Representação Binária vs. Permutação em 9 cenários de teste (Média de 5 execuções).

			Binary			**Permutation**		
ID	**N**	**M**	**Makespan**	**Std (σ)**	**Conv.**	**Makespan**	**Std (σ)**	**Conv.**
C1	20	5	238.0	0.00	10.4	219.2	1.92	57.2
C2	50	5	539.6	0.55	55.0	532.2	4.21	77.0
C3	100	5	1059.0	0.00	13.6	1055.4	3.29	46.4
C4	20	10	316.0	0.00	8.6	294.6	0.89	70.6
C5	20	20	478.0	0.00	8.8	450.6	1.67	61.2
C6	50	10	635.8	1.10	45.2	626.6	9.71	87.2
C7	100	20	1421.0	4.85	71.0	1379.0	3.24	87.2
C8	50	20	835.2	3.49	73.8	812.4	4.22	78.0
C9	100	10	1180.2	3.19	80.4	1167.2	7.50	78.2

2.3.1 Análise Crítica dos Resultados

A análise dos resultados mostra que a Representação por Permutação apresenta um desempenho consistentemente superior. Em todos os nove cenários avaliados, esta abordagem produziu valores de *makespan* mais baixos do que os obtidos com a representação Binária.

Destacam-se três observações fundamentais:

1. **Convergência prematura na representação Binária:** A representação Binária tende a convergir muito cedo, sobretudo nos cenários com menor número de *jobs* (C1, C4 e C5), onde a convergência ocorre em cerca de 10 gerações. Apesar desta rapidez, os valores de *makespan* obtidos são sistematicamente piores, o que indica que o algoritmo fica preso em soluções locais. A baixa diversidade genética limita a capacidade desta representação para explorar o espaço de procura de forma eficaz.

2. **Comportamento no cenário C3 ($N = 100$):** No cenário C3, caracterizado por um elevado número de tarefas, a representação Binária convergiu em apenas 13.6 gerações, com desvio padrão nulo. Este comportamento revela uma limitação estrutural do cromossoma binário, que rapidamente deixa de produzir soluções melhores. Em contraste, a representação por Permutação continuou a melhorar a solução até aproximadamente à geração 46.

3. **Consistência versus qualidade da solução:** A representação Binária apresentou, na maioria dos cenários, desvios padrão nulos ou muito reduzidos, indicando que converge sempre para a mesma solução. No entanto, essa solução é subótima. A representação por Permutação, embora apresente maior variabilidade nos resultados, demonstra maior capacidade de exploração do espaço de procura e conduz a soluções de melhor qualidade.

2.3.2 Avaliação de Escalabilidade

Ao analisar o comportamento dos algoritmos face à variação das dimensões do problema, retiram-se as seguintes conclusões:

Impacto do número de *jobs* (N): A representação por Permutação apresenta um crescimento mais estável do desempenho à medida que o número de tarefas aumenta ($C1 \rightarrow C2 \rightarrow C3$). Embora a dificuldade do problema aumente, esta abordagem consegue continuar a explorar o espaço de procura sem estagnar precocemente. Em contraste, a representação Binária revela limitações de escalabilidade para valores elevados de N. Tal é evidenciado no cenário C3, onde, apesar de um *makespan* competitivo, o algoritmo estagnou precocemente

(geração 13.6), sugerindo que o aumento do tamanho do cromossoma dificulta a correlação entre a codificação e a qualidade da solução. Esta limitação torna-se mais tangível no cenário C7, onde a complexidade combinada ($N = 100, M = 20$) resultou num desvio significativo de qualidade face à representação por Permutação.

Impacto do número de máquinas (M): A diferença entre as representações torna-se mais evidente quando aumenta o número de máquinas, mantendo-se um número reduzido de tarefas ($C4$ e $C5$). Nestes cenários, a representação Binária apresentou o pior desempenho relativo, com diferenças significativas no *makespan*. Por outro lado, a representação por Permutação mostrou maior capacidade para lidar com a complexidade associada à alocação de múltiplos recursos, demonstrando ser uma solução mais robusta para ambientes de produção mais exigentes.

Conclusão: Com base nos resultados apresentados na Tabela 2.5, a Representação por Permutação demonstrou desempenho superior em todos os cenários testados, obtendo sistematicamente valores de *makespan* inferiores aos da representação Binária. Embora a representação Binária apresente convergência mais rápida, esta ocorre consistentemente para soluções de menor qualidade. A superioridade da Permutação torna-se ainda mais evidente em cenários de maior escala, como o C7, confirmando-a como a escolha mais adequada quando se privilegia a qualidade da solução.

Chapter 3

Conclusão

O presente estudo realizou uma análise comparativa detalhada entre as representações Binária e de Permutação para o *Job Scheduling Problem*, evidenciando uma diferença clara entre rapidez de convergência e qualidade da solução. A representação Binária convergiu rapidamente, mas mostrou tendência a estagnar cedo em ótimos locais, limitando a qualidade final das soluções. Por outro lado, a representação por Permutação, especialmente quando combinada com a *Tournament Selection* e a mutação *Swap*, conseguiu manter maior diversidade genética, produzindo de forma consistente soluções com menor *makespan*.

A superioridade da representação por Permutação tornou-se ainda mais evidente nos testes de escalabilidade, mantendo robustez e previsibilidade à medida que a complexidade do problema aumentava. Em contraste, a representação Binária apresentou uma queda significativa de desempenho, sobretudo em cenários com maior número de máquinas. Conclui-se, portanto, que a representação por Permutação é a opção recomendada quando a otimização da produção é prioritária.

Como sugestão para trabalhos futuros, e tendo em conta que a representação Binária tende a convergir prematuramente, propõe-se a utilização de estratégias adicionais de pesquisa. O objetivo é permitir que o algoritmo identifique quando está preso em soluções locais e consiga escapar dessas zonas, retomando a exploração do espaço de procura em direção ao ótimo global.